

Estrategia Técnica y Operativa para el Desarrollo de un Escáner de Surebets Prematch en Colombia

1. Contexto Estratégico y Oportunidad de Mercado

En el competitivo ecosistema del *Arbitrage Betting*, el mercado colombiano representa una oportunidad de alta rentabilidad que los escáneres globales no logran explotar con la precisión requerida. Mientras las herramientas comerciales operan con latencias genéricas y coberturas fragmentadas, una solución propia permite una integración vertical con los operadores locales autorizados por Coljuegos. La superioridad de un desarrollo *in-house* radica en la capacidad de capturar cuotas en tiempo real adaptadas a las particularidades operativas y fiscales de Colombia, eliminando el ruido de datos de otros mercados que entorpece la ejecución. Este proyecto tiene como objetivo central la cobertura técnica exhaustiva de las cinco casas dominantes en el país: **BetPlay, RushBet, Stake, Codere y Sportium**. Mediante una arquitectura de grado empresarial, se busca transformar la captura de datos en un activo estratégico privado. Para lograr esta ventaja competitiva, es imperativo desglosar los estándares técnicos del sector y superar las deficiencias de los referentes actuales.

2. Referente Técnico: Desglosando el Modelo Betburger

Betburger representa el *benchmark* de la industria desde 2013. Su arquitectura, aunque protegida bajo un modelo de opacidad comercial, define el estándar de efectividad mediante una separación clara entre servicios *prematch* y *live* expuestos a través de APIs documentadas con Swagger. La madurez de su sistema no reside únicamente en la cantidad de datos, sino en la capacidad de procesar hasta 1,800 resultados por minuto, garantizando que el usuario final interactúe con oportunidades filtradas y técnicamente verificadas. Componentes clave de la interfaz de Betburger que optimizan la eficiencia:

- **Calculadoras Multidireccionales:** Herramientas integradas para el reparto de *stakes* considerando comisiones, redondeos y cuotas adyacentes de forma instantánea.
- **Filtros de Alta Granularidad:** Segmentación por ROI, antigüedad de la oportunidad, casas requeridas y tipos de mercado (1X2, Moneyline, Hándicaps).
- **Sistema de Alertado en Tiempo Real:** Notificaciones visuales y sonoras configurables para mitigar la expiración de cuotas.
- **Navegación Directa (Deep Links):** Enlaces profundos que dirigen al usuario directamente al cupón de apuesta de la casa, minimizando el tiempo de ejecución manual. Un factor estratégico identificado es que Betburger ya reconoce la divergencia de datos en Colombia, tratando a **RushBet y BetPlay** como entidades independientes de otros clones globales de Unibet. Esta diferenciación regional es crítica para evitar la degradación del dato. Sin embargo, para alimentar un sistema propio con este nivel de precisión, se requiere una evaluación rigurosa de las fuentes de datos disponibles.

3. Evaluación de Proveedores de Datos: El Ecosistema de APIs

El "backbone" de datos determina la viabilidad del escáner. En arbitraje, la baja latencia no es una preferencia, sino una necesidad operativa para minimizar el *slippage*. Una infraestructura robusta debe combinar proveedores agregados con soluciones de nicho.

Proveedor | Cobertura Colombia (Target 5) | Entrega de Datos | Nota Técnica || ----- | ----- | ----- || **OpticOdds** | BetPlay, RushBet, Stake, Codere. (Sin Sportium) | REST + Streaming SSE | API unificada, soporte hasta 100+ sportsbooks. || **Odds-API.io** | BetPlay, Stake. | REST + WebSocket | Latencia <150ms; el WebSocket es un add-on (2x costo). || **The Odds API** | Solo Codere (vía región EU/IT). | REST | Sin región Colombia; latencia de 60s en prematch es insuficiente. || **Scrapebet** | Codere y Sportium (Tarjetas específicas). | REST API (JSON) | Crucial para cubrir los "huecos" de los proveedores US/UK. |

La brecha crítica es evidente: **The Odds API** carece de cobertura regional colombiana, y los proveedores globales suelen ignorar a Sportium en sus *feeds* estándar. Por tanto, la solución debe ser **obligatoriamente híbrida**. El sistema consumirá APIs comerciales para el grueso del volumen y suplementará las ausencias mediante adaptadores propios.

4. Arquitectura del Sistema: El Motor de Adquisición Híbrido

Para garantizar la sostenibilidad ante cambios en las interfaces de las casas de apuestas, el sistema implementará un patrón de diseño basado en **Adaptadores**. Esta abstracción aísla la lógica de negocio de la volatilidad del *frontend* de los operadores. Como estándar de persistencia y rendimiento, se mandata el uso de **PostgreSQL** para la integridad de los datos y auditoría, y **Redis** como caché caliente para la deduplicación de cuotas en tiempo real. El flujo de captura para casos sin API (como Sportium) se realizará mediante **Playwright**, priorizando la interceptación de red sobre el raspado visual:

- **Intercepción XHR/JSON:** Captura directa de los *payloads* estructurados que alimentan la web, evitando la fragilidad del DOM Scraping.
- **Persistencia de storageState:** Almacenamiento de cookies, *localStorage* e *IndexedDB* para mantener sesiones autenticadas, evitando logins repetidos y bloqueos por comportamiento robótico. La jerarquía de adquisición para optimizar latencia (**Target: P50 < 5s, P95 < 15s**) es:
 1. **API/Feed Directo (REST/WS):** Máxima estabilidad.
 2. **Interceptación XHR/JSON públicos:** Datos estructurados sin renderizado visual.
 3. **Headless Browser (DOM Scraping):** Último recurso ante WAFs agresivos. Esta captura robusta es el prelude necesario para la fase más compleja: la unificación de la información.

5. La Capa de Inteligencia: Normalización y Matching de Eventos

La normalización canónica es la salvaguarda contra el "error más caro": comparar mercados incorrectos (ej. mezclar Hándicap Asiático con Europeo). Sin una taxonomía unificada, el sistema generará alertas falsas que resultan en pérdidas de capital. El esquema de datos canónico incluirá: sport, competition_norm, home_norm, away_norm, start_time_utc, market_family (1X2, totals, handicap), period (FT, 1H), side_code (home, away, draw, over, under), line_value y line_unit. **Tabla de Alias (Ejemplos de Normalización):** | Nombre en la Fuente | Nombre Canónico (Sistema) | | :--- | :--- | | Atl. Nacional / Nacional Med. | Atlético Nacional | | Millos / Millonarios FC | Millonarios | | Primera A - Clausura | Categoría Primera A | El **Matching Engine** operará en dos etapas:

1. **Reglas Deterministas:** Coincidencia exacta de deporte, competición, kickoff normalizado (ventana < 5 min) y nombres canónicos.
2. **Fuzzy Fallback:** Algoritmos de similitud de texto para variaciones menores, enviando los casos ambiguos a una **cola de revisión (Review Queue)** para validación humana, evitando contaminar el motor de arbitraje.

6. Motor de Arbitraje y Cálculo de Rentabilidad

La precisión matemática es el núcleo que transforma datos en rentabilidad. El motor debe procesar combinaciones basándose en la cuota apostable real, no en la teórica. **Fórmulas de Surebet:** **2-Opciones:** $\$1/O_1 + 1/O_2 < 1\$$ **3-Opciones (1X2):** $\$A = 1/O_1 + 1/O_x + 1/O_2\$$ Si $\$A < 1\$$, existe oportunidad de arbitraje. **Cálculo de Operación (Bankroll $\$B\$$):**

- **Stake por pata ($\$S_i\$$):** $\$S_i = (B * (1/O_i)) / A\$$
- **Profit Neto Bloqueado:** $\$Profit = B * ((1/A) - 1)\$$ Para el cálculo del **Edge Neto**, es obligatorio integrar los factores de fricción específicos de Colombia:
- **Impuestos:** **IVA del 19%** (Decreto 1474 de 2025) y el **Impuesto al Consumo del 16%** sobre depósitos (Decreto 0240 de 2026).
- **Fricción Operativa:** Redondeos de la casa, comisiones de retiro (withdrawal_cost_pct), y el bonus_lock_factor.
- **Slippage:** Margen de seguridad por la volatilidad de la cuota durante la ejecución.

7. Estrategia Operativa: Revalidación y Alertas en Tiempo Real

Para minimizar el riesgo de "patas colgadas" (cambios de cuota post-apuesta), el sistema ejecutará un flujo de **Recheck** obligatorio:

1. **Check Inicial:** Detección y marcado como *pending*.
2. **Espera Táctica:** Intervalo de 2 segundos para verificar estabilidad.
3. **Check Final:** Confirmación concurrente de que las cuotas y líneas siguen vigentes. El umbral de seguridad para alertas será de **ROI > 1.5% Neto**. La latencia total desde la detección hasta la alerta debe ser **inferior a 20 segundos** para garantizar la ejecutoriedad. La infraestructura de alertas integrará **n8n y Telegram**, enviando mensajes estructurados con: Evento, Mercado/Línea, Casas, Cuotas, ROI Neto, Stakes Sugeridos y Hora de Inicio (America/Bogota).

8. Marco Regulatorio y Sostenibilidad Financiera en Colombia

El proyecto opera bajo el marco de **Coljuegos**. Aunque la observación de cuotas es legal, el acceso automatizado enfrenta riesgos contractuales. Operadores como **Sportium y Codere** prohíben explícitamente el uso de "robots" o IA en sus términos de servicio. Por ello, el MVP adoptará una postura de cumplimiento conservadora: el sistema actúa como un terminal de información para el usuario, sin ejecución automática de apuestas. La sostenibilidad financiera depende del modelo de costes. Ignorar el **Decreto 0240 de 2026** (Impuesto al consumo del 16% en depósitos) y el **IVA del 19%** sobre juegos de internet (Decreto 1474) invalidaría cualquier cálculo de rentabilidad. Estos impuestos deben ser tratados como costes transaccionales directos en el motor de cálculo.

9. Hoja de Ruta de Implementación (Roadmap)

Se propone una ejecución incremental de 12 semanas para validar la tecnología antes de escalar la inversión.

- **Semanas 1-2 (Discovery):** Análisis de tráfico (HAR), recolección de storageState y definición de taxonomía canónica inicial.
- **Semanas 3-4 (Backend Base):** Configuración de **PostgreSQL y Redis**. Desarrollo del núcleo en FastAPI.
- **Semanas 5-7 (Adaptadores):** Implementación de colectores API (OpticOdds/Scrapebet) y scrapers con Playwright para las 5 casas.

- **Semanas 8-10 (Matching & Arb Engine):** Desarrollo de la lógica de emparejamiento (Deterministic + Fuzzy) y el motor de cálculo con factores fiscales.
 - **Semanas 11-12 (Alertas & Piloto):** Orquestación con n8n y Telegram. Pruebas de campo con bankroll real reducido.
- Costos Operativos Estimados (Mensuales):**
- **Infraestructura Cloud (BD + App):** \$400 - \$1,000 USD.
 - **Proxies & Headless Browsers:** \$300 - \$800 USD (Evasión de WAF/bloqueos).
 - **Mantenimiento Técnico:** Ingeniería constante para actualización de adaptadores ante cambios en el DOM. En conclusión, el desarrollo de este escáner representa un activo estratégico de alto valor. Al superar las limitaciones de las herramientas globales mediante una infraestructura híbrida, robustez en el matching y un cálculo de rentabilidad ajustado a la realidad fiscal colombiana, el sistema se posiciona como una ventaja competitiva privada e indispensable.